

رسالة محمد



# مبانی بینایی کامپیوتر

مدرس: محمدرضا محمدی




۱۴۰۱

# تناظر و هم‌ترازی تصاویر

Correspondence and Image Alignment

# آشکارساز Harris

The distribution of  $x$  and  $y$  derivatives can be characterized by the shape and size of the principal component ellipse




# آشکارساز Harris

- برای داشتن گوشه، نیاز است تا هر دو مقدار ویژه بزرگ باشند

$$R = \lambda_1 \lambda_2 - k(\lambda_1 + \lambda_2)^2$$

$$R = \det(M) - k(\text{trace}(M))^2$$






# آشکارساز Harris

- محاسبه مشتق افقی و عمودی
- محاسبه مربع مشتق‌ها
- اعمال اثر پنجره  $W$
- محاسبه مقادیر  $R$
- حذف مقادیر غیر بیشینه




$$M = \sum_{x,y} w(x,y) \begin{bmatrix} I_x^2 & I_x I_y \\ I_x I_y & I_y^2 \end{bmatrix}$$

$$M = g(\sigma_I) * \begin{bmatrix} I_x^2(\sigma_D) & I_x I_y(\sigma_D) \\ I_x I_y(\sigma_D) & I_y^2(\sigma_D) \end{bmatrix}$$

$$R = \det(M) - k(\text{trace}(M))^2$$



# آشکارساز Harris



# خواص آشکارساز Harris

- مستقل از چرخش است




- نسبت به شیفت شدت روشنایی تصویر حساس نیست

- مشتق تصویر وابسته به شیفت نیست

$$I = I + b$$

- نسبت به مقیاس شدت روشایی حساسیت مرتبه ۲ دارد


$$I = a I$$






# خواص آشکارساز Harris

- مستقل از چرخش است
- نسبت به شیفต์ شدت روشنایی تصویر حساس نیست
  - مشتق تصویر وابسته به شیفต์ نیست
- نسبت به مقیاس شدت روشایی حساسیت مرتبه ۲ دارد
- نسبت به مقیاس تصویر وابسته است




تمام نقاط لبه هستند



گوشه

# انطباق نقاط کلیدی

- پس از استخراج نقاط کلیدی از دو تصویر، نیاز است تا نقاط متناظر با یکدیگر مشخص شوند
- برای این منظور، ابتدا برای هر نقطه ویژگی یک توصیفگر محاسبه می‌شود
- سپس، دو به دو توصیفگرها از دو تصویر مقایسه می‌شوند و مشابه‌ترین توصیفگرها به عنوان نقاط متناظر انتخاب می‌شوند
- برای جلوگیری از تناظریابی اشتباه، حد آستانه‌ای بر روی میزان مشابهت گذاشته می‌شود



# از نقاط به ناحیه‌ها

- آشکارساز Harris نقاط کلیدی را مشخص می‌کند

- مکان‌یابی دقیق

- تکرارپذیری بالا


- به منظور مقایسه این نقاط، نیاز داریم تا هر نقطه توسط یک توصیفگر بر روی ناحیه اطراف خود بازنمایی

شود

- چطور می‌توانیم یک ناحیه مستقل از مقیاس تعریف کنیم؟




# مقایسه ناحیه‌ها



Similarity  
measure

$\neq$

$d(f_A, f_B)$







# رویکرد Naïve: جستجوی کامل


- روش چند مقیاسه:

- توصیفگرها برای ناحیه‌های با ابعاد متفاوت محاسبه و مقایسه شوند
- این محاسبات برای هر جفت نقاط از دو تصویر بسیار هزینه‌بر خواهد بود




# انتخاب خودکار مقیاس

- تابعی طراحی کنیم که مستقل از مقیاس باشد
  - برای ناحیه‌های متناظر یکسان باشد حتی اگر مقیاس متفاوتی داشته باشند
  - به عنوان مثال، میانگین شدت روشنایی مستقل از مقیاس است و برای دو ناحیه متناظر مقدار یکسانی دارد
- برای یک نقطه در یک تصویر، می‌توان میانگین شدت روشنایی را به صورت تابعی از ابعاد ناحیه لحاظ کرد




# انتخاب خودکار مقیاس


- ابعاد مربوط به بیشینه محلی در این منحنی متناسب با مقیاس خواهد بود
- نکته مهم این است که محاسبات مربوط به یافتن اندازه ناحیه در هر تصویر و برای هر نقطه کلیدی به صورت مستقل انجام می‌شود



# انتخاب خودکار مقیاس




$$f(I_{i_1...i_m}(x, \sigma))$$




$$f(I_{i_1...i_m}(x', \sigma))$$



# انتخاب خودکار مقیاس





$$f(I_{i_1...i_m}(x, \sigma))$$




$$f(I_{i_1...i_m}(x', \sigma))$$

# انتخاب خودکار مقیاس





$$f(I_{i_1 \dots i_m}(x, \sigma))$$




$$f(I_{i_1 \dots i_m}(x', \sigma))$$

# انتخاب خودکار مقیاس





$$f(I_{i_1...i_m}(x, \sigma))$$




$$f(I_{i_1...i_m}(x', \sigma))$$



# انتخاب خودکار مقیاس





$$f(I_{i_1 \dots i_m}(x, \sigma))$$



$$f(I_{i_1 \dots i_m}(x', \sigma))$$



# انتخاب خودکار مقیاس

- پس از انتخاب ابعاد مناسب، ناحیه‌ها را به یک اندازه مشخص نرمالیزه می‌کنیم تا به خوبی قابل مقایسه باشند



# انتخاب خودکار جهت

- نیاز است تابعی طراحی کنیم که متناسب با مقدار چرخش تصویر، تغییر کند
- می‌توان ابتدا هیستوگرام جهت گرادیان را محاسبه کرد
- سپس، جهت غالب در این هیستوگرام را انتخاب کرد






# نقاط کلیدی

• روش‌های پرکاربرد برای استخراج نقاط کلیدی و توصیفگرهای آنها عبارتند از:

SIFT -


SURF -

ORB -



# انطباق نقاط کلیدی


- پس از استخراج نقاط کلیدی از دو تصویر، نیاز است تا نقاط متناظر با یکدیگر مشخص شوند
- برای این منظور، ابتدا برای هر نقطه ویژگی یک توصیفگر محاسبه می‌شود
- سپس، دو به دو توصیفگرها از دو تصویر مقایسه می‌شوند و مشابه‌ترین توصیفگرها به عنوان نقاط متناظر انتخاب می‌شوند
- برای جلوگیری از تناظریابی اشتباه، حد آستانه‌ای بر روی میزان مشابهت گذاشته می‌شود







# تابع تبدیل

- پس از یافتن نقاط متناظر، باید تابع تبدیلی را بدست آورد که نقاط تصویر اول را به نقاط تصویر دوم نگاشت کند
- برای این کار، ابتدا یک مدل برای تابع تبدیل انتخاب می‌شود و سپس پارامترهای آن بر اساس نقاط بدست آمده بهینه می‌شوند



$$\begin{bmatrix} x_2 \\ y_2 \end{bmatrix} = T \left( \begin{bmatrix} x_1 \\ y_1 \end{bmatrix} \right)$$

# تبدیل‌های هندسی




$$\begin{bmatrix} x_2 \\ y_2 \end{bmatrix} = T \left( \begin{bmatrix} x_1 \\ y_1 \end{bmatrix} \right)$$

# انتقال

$$\begin{bmatrix} x_2 \\ y_2 \end{bmatrix} = \begin{bmatrix} x_1 \\ y_1 \end{bmatrix} + \begin{bmatrix} t_x \\ t_y \end{bmatrix}$$

- پارامترهای مدل  $(x_t, y_t)$  بر اساس نقاط متناظر محاسبه می‌شوند
- نیازمند تنها ۱ نقطه است!

- به دلیل وجود خطا در مکان‌یابی دقیق نقاط کلیدی، می‌توان با استفاده از تعداد بیشتری نقطه به پارامترهای دقیق‌تری دست یافت



$$\begin{bmatrix} x_2 \\ y_2 \end{bmatrix} = T \left( \begin{bmatrix} x_1 \\ y_1 \end{bmatrix} \right)$$



# حداقل مربعات خطا

$$\begin{bmatrix} x_2 \\ y_2 \end{bmatrix} = \begin{bmatrix} x_1 \\ y_1 \end{bmatrix} + \begin{bmatrix} t_x \\ t_y \end{bmatrix}$$

- تابع هزینه

$$cost = \sum (x_2^n - x_1^n - t_x)^2 + (y_2^n - y_1^n - t_y)^2$$

- بهینه‌سازی

- محاسبه مشتق

$$\frac{d}{dt_x} cost = -2 \sum (x_2^n - x_1^n - t_x) = 0$$

$$\Rightarrow t_x = \frac{1}{N} \sum (x_2^n - x_1^n) \quad t_y = \frac{1}{N} \sum (y_2^n - y_1^n)$$

# داده‌های پرت

- روش حداقل مربعات خطا حساس به داده‌های پرت است
- روش RANSAC برای بدست آوردن تابع تبدیل مقاوم نسبت به داده‌های پرت استفاده می‌شود

